

UNIVERSITATEA BABEȘ-BOLYAI

Facultatea de Științe Economice și Gestiunea Afacerilor

Statistica și previziune economică

Lucrare de licență

Absolvent,
Florin Despa

Coordonator științific,
Lect. univ. dr. **Anita Todea**

2021

UNIVERSITATEA BABEȘ-BOLYAI

Facultatea de Științe Economice și Gestiunea Afacerilor

Statistica și previziune economică

Lucrare de licență

**Expunerea la riscul global al piețelor de capital din Centrul
și Estul Europei**

Absolvent,

Florin Despa

Coordonator științific,

Lector univ. dr. **Anita Todea**

2021

Rezumat: În această lucrare am studiat dinamica integrării piețelor de capital din Centrul și Estul Europei în perioada crizei financiare din 2007-2009. Plecând de la crearea modelelor de piață a activelor financiare din Centrul și Estul Europei am ajuns la concluzia că piețele locale sunt expuse la riscul piețelor globale într-o măsură destul de semnificativă, mai ales în perioada unei crize economice. Chiar dacă economia și-a revenit, piețele locale au rămas semnificativ influențate de către piața globală și după criza financiară. Deasemenea s-a constatat că piețele locale devin semnificativ mai corelate cu piețele internaționale în timpul unei perioade de criză.

Cuprins

Introducere	5
Lista tabelelor și a figurilor	7
Capitolul 1: Riscul activelor financiare	8
1.1 Definiții ale conceptului de risc	8
1.2. Metode de cuantificare a riscului	8
1.3. Metode de diminuare ale riscului	16
Capitolul 2: Lucrări de specialitate.....	18
2.1 Studii ce analizează efectul piețelor globale de capital asupra piețelor locale din timpul crizei din 2007-2009	18
2.2. Studii în care se previzionează valorile activelor financiare folosind modelul GARCH.....	22
2.3 Studii ce investighează legătura dintre riscul activelor financiare și al diferitelor mărfuri	24
2.4 Studii ce analizează piața emisiilor de carbon.....	25
Capitolul 3: Expunerea la riscul global al piețelor de capital din Centrul și Estul Europei.....	28
3.1. Baza de date.....	28
3.2. Metodologia de studiu.....	32
3.3. Rezultate empirice	34
Concluzii	48
Bibliografie	49

Introducere

În această lucrare mi-am propus să analizez expunerea piețelor de capital din CEE (Centrul și Estul Europei) la riscul global. Deoarece piețele de capital ale lumii devin din ce în ce mai integrate datorită globalizării, piețele locale devin din ce în ce mai susceptibile la anomalii economice ce ar putea apărea pe diferite piețe de capital și normal nu ar avea un efect semnificativ asupra economiei locale. Câteva exemple de anomalii ar fi evenimente de tip “black-swan”, pandemii, falimentul unor corporații extinse la nivel global (ex: Lehman Brothers), interdependență economică asimetrică (ex: conflictul Diayutai dintre China și Japonia din 1970). Acest tip de evenimente ar putea rezulta într-o criză financiară, ca și cea din anii 2007-2009 ce a pornit în Statele Unite ale Americii și s-a resimțit în toată lumea. Această criză, intitulată și marea criză financiară sau marea recesiune, este considerată a fi una dintre cele mai lungi și semnificative crize economice de până acum (Bordo & Haubrich, 2017). Mulți factori au contribuit la această criză, cum ar fi creșterea datoriilor din cauza introducerii unor noi instrumente financiare, acordarea de credite ipotecare riscante (sub-prime mortgages) sau lipsa reglementărilor. Efectele principale pe care le-a avut criza sunt scăderea creșterii economice, rată a șomajului ridicată, datorii mari ale marilor sectoare publice, o mai mare influență a politicii asupra economiei, scăderea inflației și dobânzi foarte mici.

Am realizat această lucrare pentru a contribui la o mai bună înțelegere a dinamicii activelor financiare într-o perioadă de criză. Deasemenea rezultatele analizei pot fi de folos investitorilor ce vor să își diversifice portofoliul cu active financiare din Centrul și Estul Europei, deasemenea rezultatele pot ajuta la luarea unor decizii mai bune în contextul politicilor economice al regiunilor din CEE.

Ca metodologie de lucru am realizat analiza în două părți: În prima parte vom crea modelul de piață explicitând randamentul pieței locale cu ajutorul randamentul pieței globale. Rezultatele acestui proces o să ne dea o idee despre cât de mult este influențată piața locală de cea globală. În a doua parte a analizei vom măsura riscul într-o manieră dinamică în timp folosind modelul multivariat DCC GARCH(1,1). Cu ajutorul acestei analize vom vedea mișcările comune ale indicilor și cât de corelate sunt valorile indicilor analizați. Având în vedere că perioada de criză a fost o perioadă disruptivă pentru economia globală, am realizat analiza pe trei perioade de timp (înainte de criza din 2007, în timpul crizei, și după criză), datele folosite fiind prețurile de închidere zilnice ale indicilor țărilor din CEE, indicele MSCI (indice ce reprezintă piața globală) și indicii internaționali DAX30, S&P500, FTSE100, Nikkei225, CAC40, pe o perioadă de 16 ani (ian. 2004- dec. 2019).

Lucrarea este împărțită în trei capitole: În primul capitol am revizuit literatura de specialitate și am scris teoria necesară pentru realizarea lucrării. În capitolul 2 am descris pe scurt alte lucrări de specialitate ce au abordat o temă asemănătoare cu a lucrării de față, iar în al treilea capitol am analizat riscul la care sunt expuse piețele locale din CEE din cauza piețelor globale.

Lista tabelelor și a figurilor

Figura 1.1 Riscul de piață și riscul specific	17
Figura 2.1 Corelațiile condiționale dinamice ale seriilor analizate	20
Figura 2.2 Previziunea indicelui Ibovespa	23
Tabelul 3.1 Statistici descriptive	29
Tabelul 3.2 Statistici descriptive pentru întreaga perioadă analizată	31
Figura 3.1 Rentabilitatea logaritmică a indicelui MSCI	31
Tabelul 3.3 Ecuatiile volatilităților dintre indicii analizați și indicele MSCI	35
Tabelul 3.4 Ecuatiile volatilităților dintre indicii analizați și indicele DAX	36
Tabelul 3.5 Corelările dintre indicii locali și indicii globali	38
Figura 3.2 Corelările dintre indicele BET și indicii globali	40
Figura 3.3 Corelările dintre indicele BUX și indicii globali	42
Figura 3.4 Corelările dintre indicele PX și indicii globali	44
Figura 3.5 Corelările dintre indicele MOEX și indicii globali	45
Figura 3.6 Corelările dintre indicele WIG și indicii globali	47

Capitolul 1: Riscul activelor financiare

1.1 Definiții ale conceptului de risc

Definiția dată de dicționarul Cambridge riscului este “posibilitatea de a se întâmpla ceva rău/ ceva ce duce la consecințe negative”. Riscul este asociat de foarte multe ori cu incertitudinea, există totuși o distincție între acestea. Diferența este evidențiată de către economistul Frank Knight, de la Universitatea din Chicago, în anul 1921. În general, riscul implică decizii a căror consecințe sunt aleatoare, dar probabilitățile asociate cu aceste consecințe sunt cunoscute. Putem lua ca exemplu pariurile, avem risc, dar nu avem incertitudine, deoarece știm rezultatele posibile ale pariului. Ca și exemplu pentru incertitudine putem lua comportamentul jucătorilor (ca și exemplu, “bluffing-ul”) într-un joc de poker în care riscul poate fi modelat într-un pachet de cărți. Astfel, riscul este amplificat de incertitudine și în cele din urmă ajungându-se la concluzia că modelele standard de măsurare a riscului nu sunt suficient de bune într-o lume în care incertitudinea devine din ce în ce mai accentuată.

Riscul este deasemenea definit în finanțe ca posibilitatea ca rentabilitatea reală a unei investiții să fie mai mică decât rentabilitatea așteptată pentru investiția respectivă. Orice investiție are un anumit risc și randamentul acesteia este strâns corelat cu mărimea riscului asumat. Cu cât riscul este mai mare cu atât randamentul investiției este mai mare. Această relație este cunoscută ca “risk return trade-off”. Pentru a explica relația inversă, ne putem imagina un investitor care are o aversiune ridicată asupra riscului și se mulțumește cu randamentul care vine cu acel nivel de risc. Dacă investitorului i se oferă o altă investiție cu un risc mai ridicat, este normal ca acesta să aștepte un randament mai ridicat pentru a compensa creșterea riscului.

1.2. Metode de cuantificare a riscului

Obiectivul principal al măsurilor de risc este de a ajuta în procesul de decizie. Măsurarea și controlarea riscului este una dintre cele mai mari probleme în toate domeniile moderne de activitate existente, inclusiv piețele financiare. Scopul principal al piețelor financiare este de a ajusta zilnic mii de prețuri, astfel generând cantități foarte mari de date ce pot fi analizate statistic. Măsura riscului este mai ușor

de realizat în finanțe decât în alte ramuri de activitate, datorită volumului mare de date disponibile, dar și datorită faptului că riscul are o definiție mai robustă.

Există o subtilă diferență între termenii măsură a riscului și măsurarea riscului. Prima este definiția metodei de măsurare, iar a doua este măsurarea propriu-zisă. Măsură de risc reprezintă o metodă matematică pentru determinarea riscului. Cele mai folosite măsuri ale riscului sunt: volatilitatea, valoarea la risc și deficitul anticipat. Măsurarea riscului este realizată prin aplicarea de date asupra unei metode de măsură a riscului.

Volatilitatea

Volatilitatea este în general considerată o măsură adecvată pentru riscul asociat cu o anumită investiție. Există două tipuri de volatilitate: necondiționată și condiționată. Volatilitatea necondiționată (notată cu σ) reprezintă volatilitatea rentabilității pe întreaga perioadă analizată, iar cea condiționată (notată cu σ_t) arată volatilitatea dintr-o anumită perioadă de timp.

În finanțe, volatilitatea este reprezentată de către varianță sau rădăcina pătrată a varianței (abaterea medie pătratică). Cu cât varianța sau abaterea medie pătratică a rentabilității unui titlu este mai mare, cu atât riscul asociat cu titlul respectiv este mai mare.

Vom nota cu R_t^L rentabilitatea logaritmică la momentul t, definită prin:

$$R_t^L = \ln \left(\frac{C_t}{C_{t-1}} \right)$$

R_t^L , rentabilitatea logaritmică la momentul t

C_t , prețul titlului la momentul t

C_{t-1} , prețul titlului la momentul t-1

Pe termen lung, rentabilitățile oferite de acțiuni sunt mult mai mari decât rentabilitățile oferite de obligațiuni sau certificate bonuri de trezorerie, însă în cazul acțiunilor avem o variabilitate mult mai mare în timp, o incertitudine mai mare(risc).

Varianța este calculată folosind următoarea formulă:

$$\sigma^2(R_i) \cong \frac{1}{T-1} \sum_{t=1}^T (R_{i,t} - \bar{R}_i)^2$$

unde $R_{i,t}$, reprezintă rentabilitatea activului i la momentul t .

Varianța este valabilă ca măsură a riscului numai în măsura în care procesul de evoluție al rentabilităților este staționar. Un proces este staționar în varianță dacă varianța este constantă în timp. Acest lucru este fals în majoritatea cazurilor, deoarece avem perioade în care varianța are valori mari și perioade în care are valori mici. Ca de exemplu în mijlocul anilor 1990 volatilitatea era scăzută, iar la începutul și sfârșitul deceniului volatilitatea avea valori foarte mari. Aceste perioade de volatilitate sunt denumite clustere de volatilitate (volatility clusters), termenul fiind introdus în publicația lui Engle (1982) și este comun acceptat că fiind una dintre caracteristicile stilizate ale rentabilității titlurilor.

Pentru a obține abaterea medie pătratică tot ce trebuie să facem este să punem varianța sub un radical. Abaterea medie pătratică ne arată cu cât se abat în medie pătratică rentabilitățile titlurilor de la valoarea medie. Cu cât abaterea medie pătratică este mai mare cu atât riscul mediu zilnic este mai mare, deoarece rentabilitatea variază mai puternic.

O altă măsură a riscului este semivarianța, care se estimează la fel ca varianța, doar că în calcul se iau doar rentabilitățile activelor financiare care sunt mai mici sau cel mult egale cu rentabilitatea așteptată; putem scoate radicalul și obținem riscul de scădere (downside risk).

$$SV = \frac{1}{T-1} \sum_{t=1}^T (R_{i,t} - E(R_i))^2$$

unde $R_{i,t} < E(R_i)$,

$E(R_i)$ fiind speranța rentabilității activului i

Coeficientul beta măsoară deasemenea volatilitatea unui activ sau al unui portofoliu și o compară cu un benchmark. Coeficientul beta este folosit în CAPM (Capital Asset Price Model), care utilizează

riscul și rentabilitatea pentru a evalua valoarea unui activ. Un beta mai mare decât 1, arată că activul este mai volatil decât piața din care face parte, acest lucru presupunând un risc mai mare. Dacă beta este mai mic decât 1, atunci activul este mai puțin riscant decât piața în general. Există de asemenea cazuri în care beta ia valori negative ceea ce înseamnă că atunci când piața este foarte volatilă și riscantă, aceste active se vor comporta opus pieței, ele având volatilitatea și riscul mai scăzute.

$$\hat{\beta}_j = \frac{cov(R_j, R_M)}{\sigma^2(R_M)}$$

$\hat{\beta}_j$, coeficientul beta,

R_j , rentabilitatea activului j,

R_M , rentabilitatea pieței

Value at risk (VaR)

Înainte de criza din 2007, una dintre cele mai folosite metode era “value at risk”/ “valoare la risc” (VaR). Metoda de măsură a riscului VaR ne informează cu privire la ce proporție din portofoliu este supusă riscului, într-un anumit interval de timp, cu o anumită probabilitate de garantare. Această metodologie asumă că randamentele sunt distribuite normal, când de fapt, în general nu sunt. Mai mult, în timpul unei perioade de incertitudine pe piață, coada distribuției randamentelor este mai mare/lată decât a unei distribuții normale, ceea ce înseamnă că pierderile sunt subestimate în această perioadă. Chiar și așa, metoda VaR este una dintre cele mai folosite metode în industria financiară. Când sunt luate în considerare proprietățile teoretice, problemele de implementare și testarea, această metodă devine una dintre cele mai practice metode disponibile.

VaR este quartila de pe distribuția profitului și a pierderilor (P/L). Dacă deținem o unitate dintr-un portofoliu Q, P/L va fi indicat de:

$$Q = P_t - P_{t-1}$$

Densitatea lui P/L este redată de $f_q(x)$. Atunci VaR este dat de:

$$\Pr[Q \leq -VaR(p)] = p$$

sau

$$p = \int_{-\infty}^{-VaR(p)} f_q(x) dx$$

Folosim semnul minus deoarece VaR este un număr pozitiv, iar noi avem de-a face cu pierderi, așa că, probabilitatea de pierdere este mai mare (mai negativă) decât VaR negativ.

VaR poate fi interpretat și ca pierderile potențiale minime pe care un portofoliu le poate suferii. VaR este “cel mai bun caz din cele mai rele cazuri” și inevitabil va subestima pierderile potențiale asociate cu un anumit nivel de probabilitate. De exemplu, valoarea zilnică VaR este la 5% nivel de încredere, ceea ce înseamnă că în 95 din 100 de zile scăderile de preț sunt așteptate să fie mai mici decât valoarea VaR și pentru 5 zile prețurile vor depăși valoarea VaR. Ca și consecință, 5% VaR este incapabil să captureze riscul mișcărilor extreme de pe piață care au o probabilitate mai mică de 5%.

Metoda VaR este cea mai relevantă atunci când perioada de deținere a unui titlu este scurtă, cea mai bună variantă fiind deținerea timp de o zi. Dacă avem o perioadă mai mare de timp, există posibilitatea să apară probleme de scalare sau VaR să își schimbe semnul. Pe de altă parte, dacă perioada de timp este mai mică de o zi, apar probleme datorită dinamicii tranzacțiilor din timpul unei zile.

Deficit așteptat (expected shortfall)

Această măsură pentru risc vine în completarea lui VaR și oferă mai multă informație despre forma cozii. Deficitul așteptat sau anticipat răspunde la întrebarea: Care este pierderea așteptată atunci când pierderile depășesc valoarea VaR?

Asumand că distribuția funcției portofoliului este continuă, răspunsul la întrebarea de mai sus este dat de o valoare condiționată așteptată mai mică decât quartila asociată cu probabilitatea p .

Ca și formulă pentru deficitul așteptat (ES) avem:

$$ES = -E[Q|Q \leq -VaR(p)]$$

sau

$$ES = - \int_{-\infty}^{-VaR(p)} x f_{VaR}(x) dx$$

O altă măsură a riscului, de o manieră variabilă în timp este folosirea modelelor heteroscedastice GARCH dezvoltate în publicația lui Bollerslev din anul 1986. Aceste modele au avut la bază cercetarea lui Engle (1982) care aduce în discuție modelele autoregresive condiționale heteroscedastice (ARCH). Modelele de tip GARCH sunt o generalizare a modelelor ARCH și sunt folosite pe piețele financiare atunci când vrem să vedem evoluția în timp a corelărilor dintre două sau mai multe titluri. Aceste modele pot fi folosite în orice studiu empiric, ca și articole științifice, licențe sau disertații, unde prezicerea incertitudinii joacă un rol important.

Pe partea de modelare, cea mai de bază metodă cantitativă pentru cercetătorii în finanțe este modelul OLS (ordinary least squares). Acest lucru se datorează faptului că foarte des econometricienii sunt puși în poziția de a determina cât de mult o variabilă se schimbă ca și urmare a unei schimbări într-o altă variabilă. (Engle, 2001). Staționaritatea devine o problemă atunci când modelăm rentabilitatea financiară, activele financiare având în general volatilitate diferită pe diferite perioade de timp (heteroscedasticitate). În aceste situații modelul OLS poate da rezultate eronate. În existența heteroscedasticității, coeficienții regresiei OLS rămân nedeplasați (unbiased), dar eroarea standard și intervalele de încredere vor fi estimate ca fiind prea înguste/mici, oferind astfel un sens fals de acuratețe Engle (2001). Necesitatea de a lua în considerare heteroscedasticitatea ce apare în activele financiare a dus la crearea modelelor ARCH și GARCH care i-au în considerare heteroscedasticitatea ca o varianță ce trebuie modelată (Engle, Focardi, & Fabozzi, 2012). Inițial, premisa că varianța este constantă într-un model este numită homoscedasticitate. Varianța inconstantă este punctul cheie al modelelor ARCH și GARCH. Modelul ARCH a fost prezentat de către Engle (1982) și urmărește să estimeze volatilitatea ce este diferită de la o perioadă la alta printr-o funcție a volatilității observate trecute. Folosind notația matematică folosită de către Tsay (2005), putem scrie un model ARCH(m) astfel:

$$R_t = \sigma_t \varepsilon_t \text{ (media condiționată)}$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 R_{t-1}^2 + \alpha_q R_{t-q}^2 \text{ (varianța condiționată)}$$

R_t , randamentul unui activ financiar

σ_t^2 , volatilitatea condiționată de timp

α_q , parametrii modelului ARCH, de obicei estimați din date reale

Deseori modelul ARCH necesită un număr mare de parametrii/ lag-uri pentru a explica volatilitatea rentabilității unui activ (Tsay, 2005). Această problemă a fost rezolvată de către Bollerslev (1986) creând o modalitate prin care varianța condiționată devine un proces ARMA (Autoregressive moving average). În alte cuvinte, modelul GARCH este un model ARCH cu foarte multe lag-uri. Formula pentru un model GARCH (p,q) este următoarea:

$$R_t = \sigma_t \varepsilon_t \text{ (media condiționată)}$$

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i R_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \text{ (varianța condiționată)}$$

ε_t este o secvență de variabile aleatoare independente și identic distribuite cu media egală cu 0, varianța egală cu 1, $\alpha_0 > 0$ dacă $i > 0$. Cu aceste proprietăți, coeficienții α_i satisfac condițiile care asigură ca varianța necondiționată este finită și pozitivă. În practică, este deseori considerat ca ε_t urmează o distribuție normală, testul student t standardizat sau o distribuție normală generalizată. Dacă toate valorile lui β_j ar fi egale cu zero, modelul GARCH (p,q) ar fi egal cu un model ARCH(q).

Parametrii unui model GARCH sunt estimați din date/ seria de timp. Metoda standard de a estima parametrii unui model GARCH este numită maximum likelihood (ML). Această metodă vrea să găsească parametrii care potrivesc cât mai bine distribuția predicțiilor/ previziunilor cu distribuția datelor reale.

Modelele de tip GARCH se împart în două categorii: univariate și multivariate. Modelele univariate GARCH sunt folosite pentru a modela și a prezice volatilitatea unei serii de date, în timp ce modelele multivariate modelează și prezic volatilitatea mai multor serii de date acolo unde există o legătură între ele.

Modelul folosit în analiza acestei lucrări este modelul DCC GARCH. Modelul DCC GARCH este o generalizare a modelului CCC GARCH (Bollerslev, 1990) și are un avantaj computațional față de CCC GARCH deoarece numărul de parametri ce trebuie estimați în procesul de corelare sunt independenți de numărul seriilor ce sunt de corelat. Astfel se poate estima folosind matrici de corelare de dimensiuni mai mari dacă este nevoie. Modelul DCC GARCH a fost introdus de Engle (2002) și Tse and Tsui (2002) și este potrivit pentru a investiga market spillover (influența piețelor de capital asupra altor piețe de capital) și efectul de contagiune prin ilustrarea schimbărilor interdependențelor globale a diferitor clase de active din diferite piețe.

Presupunem că avem randamentele a_t , pentru n active cu valoarea așteptată egală cu 0 și matricea de covarianță H_t , atunci modelul DCC (Dynamic Conditional Correlation) GARCH este definit:

$$r_t = \mu_t + a_t$$

$$a_t = H_t^{1/2} z_t$$

$$H_t = D_t R_t D_t$$

$r_t, n \times 1$ vector de rentabilități logaritmice a n active la timpul t

$a_t, n \times 1$ vector de rentabilități corectate prin medie a n active la timpul $t, E[a_t] = 0, Cov[a_t] = H_t$

$\mu_t, n \times 1$ vectori de valori așteptate a condiționalei r_t

$H_t, n \times n$ matricea varianțelor condiționate ale a_t la timpul t

$H_t^{1/2}$, Orice matrice $n \times n$ la un timp t ca și H_t este matricea de varianțe condiționale ale lui a_t . $H_t^{1/2}$ poate fi obținut prin factorizarea Cholesky a lui H_t

$D_t, n \times n$ matricea diagonală a deviațiilor standard condiționale ale a_t la timpul t

$R_t, n \times n$ matricea corelațiilor condiționale ale a_t la timpul t

$$z_t, n \times 1 \text{ vector de erori ca } \mathbb{E}[z_t] = 0, \mathbb{E}[z_t z_t^T] = I$$

1.3. Metode de diminuare ale riscului

Cea mai cunoscută și utilizată metodă de diminuare a riscului folosită asupra unui portofoliu este diversificarea. Harry Markowitz a publicat în anul 1952 o lucrare în care demonstrează beneficiile diversificării printr-un model bine definit, lucrarea câștigând premiul Nobel în economie.

Pentru a înțelege mai bine conceptul de diversificare, vom lua ca exemplu un portofoliu riscant care are o acțiune Tesla, Inc. Acest portofoliu este afectat de două tipuri de risc, primul fiind riscul sistematic sau riscul economiei generale, redat de inflație, dobânzi, rate de schimb și așa mai departe. Al doilea tip de risc este riscul specific firmei respective cum ar fi tipul de management folosit, strategia sau filozofia companiei Tesla. Factorii specifici sunt acei factori care afectează semnificativ compania Tesla, dar nu și alte companii.

Dacă adăugăm un nou titlu portofoliului nostru (de exemplu compania Ford Motor) și investim jumătate din portofoliu în Tesla și jumătate în Ford, riscul nostru se diminuează. Acest lucru este valabil dacă riscul specific al celor două companii diferă (sunt independente sau nu sunt corelate). Ca de exemplu, când prețul de producție al bateriilor scade, acțiunile companiei Tesla cresc, deoarece compania poate să producă mai multe baterii cu același capital disponibil. Pe de altă parte, acțiunile companiei Ford s-ar putea să scadă, deoarece mașinile electrice devin din ce în ce mai accesibile și convenabile, iar compania Ford produce în principal mașini ce folosesc combustibil, nu electricitate.

Adăugând noi titluri în portofoliu se reduce din ce în ce mai mult riscul/ volatilitatea coșului de titluri. Însă riscul nu va ajunge niciodată la zero datorită existenței riscului sistematic.

În figura 1.1 se poate observa că pe axa Y avem varianța portofoliului, iar pe axa X avem numărul de titluri dintr-un portofoliu. Cu verde avem reprezentat riscul portofoliului, acesta scăzând odată cu creșterea numărului de titluri. Riscul pieței sau riscul sistematic influențează toate titlurile din portofoliu, așa că nu poate fi “contrabalansat” pentru a diminua riscul și mai mult.




Figura 1.1 Riscul de piață și riscul specific

Pentru a construi un portofoliu eficient din titluri riscante, trebuie să înțelegem cum interacționează rentabilitățile titlurilor respective. O măsură de a determina cât de riscant este un portofoliu este covarianța dintre rentabilități. Cu cât avem o covarianță mai mare (rentabilitățile evoluează în același sens) cu atât un portofoliu este mai riscant și viceversa.

Riscul poate fi diminuat și mai mult dacă adăugăm în coșul de titluri, active fără risc (obligațiuni, bonuri de trezorerie). Adăugând un astfel de titlu, portofoliul poate fi construit astfel încât să producă același randament și să aibă un risc mai mic, decât un portofoliu alcătuit doar din titluri riscante.

Capitolul 2: Lucrări de specialitate

În acest capitol am observat și sumarizat lucrări care au folosit metode asemănătoare cu a mea pentru studierea volatilității unor serii de timp/ piețe de capital.

2.1 Studii ce analizează efectul piețelor globale de capital asupra piețelor locale din timpul crizei din 2007-2009

Efectul de contagiune în piețele emergente: Rezultate obținute cu ajutorul modelului DCC-GARCH – autor: Sibel Celik (2012)

Această lucrare are scopul de a testa existența efectului de contagiune dintre piețele de schimb valutar ale mai multor țări emergente și dezvoltate în timpul crizei financiare din anii 2007-2009. Aceste țări fiind: Statele Unite ale Americii (US), Australia, Brazilia, Canada, China, Danemarca, India, Japonia, Malaezia, Mexic, Noua Zeelandă, Norvegia, Singapore, Africa de Sud, Coreea de Sud, Suedia, Elveția, Taiwan, Thailanda și Turcia.

În această lucrare avem definită noțiunea de contagiune ca o creștere semnificativă în corelațiile dintre piețe în timpul unei perioade de criză. Pentru a observa acest lucru este necesar să comparăm corelațiile din perioade relativ stabile, înainte de criză (3 ianuarie 2005 – 16 iulie 2007) și perioada de criză (17 iulie 2007 – 31 august 2009). Astfel dacă două piețe sunt corelate moderat în perioade de stabilitate economică și un shock într-una dintre piețe duce la o creștere semnificativă a mișcării comune a piețelor, acest lucru va genera contagiune. O altă concluzie a efectului de contagiune este că asimetria informațională crește efectul de contagiune.

După ce s-au calculat rentabilitățile logaritmice ale randamentelor piețelor valutare s-a folosit un model DCC GARCH dezvoltat de Engle (2002) pentru a testa contagiunea din timpul crizei financiare din 2007-2009. S-a folosit un astfel de model deoarece este posibilă detectarea schimbărilor corelațiilor condiționale în timp, iar datorită faptului că volatilitatea este ajustată de procedura modelului, corelația condițională dinamică (DCC) nu este influențată (biased) de către volatilitate.

Rezultatele analizei arată că s-au găsit evidențe de contagiune în cazul majorității țărilor analizate. Analizând coeficienții corelațiilor condiționale s-a ajuns la concluzia că nu există nici o evidență care să ateste că există contagiune pe piețele valutare din Japonia, Africa de Sud, Elveția și Thailanda. Deasemenea s-a concluzionat că țările emergente par a fi cele mai influențate de efectul de contagiune din US. Aceste rezultate au fost așteptate, deoarece piețele emergente sunt mult mai instabile decât cele dezvoltate.

Impactul crizei asupra autonomiei monetare din Centrul și Estul Europei – autori: Gábor Dávid Kiss și Andreász Kosztopulosz (2012)

Studiul are ca obiectiv analizarea impactului schimbărilor randamentelor obligațiunilor și cursurilor de schimb din zona Euro și a politicilor monetare luate de Banca Centrală Europeană (BCE) asupra randamentelor piețelor de obligațiuni din Estul și Centrul Europei (Republica Cehă, Ungaria, și Polonia) între anii 2002 și 2011.

În lucrare, primul pas a fost analizarea randamentele de 10 ani (10Y) și de 3 luni (3M) din țările CEE pentru a vedea dacă există schimbări rezultate din acțiunile luate de BCE. Dacă acțiunile luate de Banca Centrală Europeană în răspuns pentru lipsa lichidității pe piață de capital din timpul crizei din 2008 au făcut ca diferența dintre randamentele de 10 ani și cele de 3 luni să crească, atunci putem spune că un efect extern a fost observat.

Al doilea pas realizat a fost respingerea principiului de piață eficientă și mers aleator testând dacă avem distribuție normală, non-autocorelare și homoscedasticitate în mișcările pieței. Pentru a vedea dacă avem o distribuție normală s-a folosit testul Jarque-Bera, pentru a vedea dacă seria este staționară s-a folosit augmented Dickey-Fuller (ADF), iar pentru a demonstra autocorelare și heteroscedasticitate s-a folosit testul ARCH-LM. În urma analizei s-a observat că rentabilitățile logaritmice nu urmează o distribuție normală, boltirea leptokurtică fiind departe de valoarea așteptată, indicând un număr mare de valori extreme (heavy-tailness). Testul ADF sugerează că rentabilitățile logaritmice sunt staționare, totuși mare parte din seria de timp oferă semne de prezență a heteroscedasticității și a autocorelării, lucru ce confirmă necesitatea utilizării modelului GARCH.

In urmatorul pas s-au comparat corelațiile condiționate ale mișcărilor piețelor derivate din diferite modele GARCH și din transformarea Fisher.

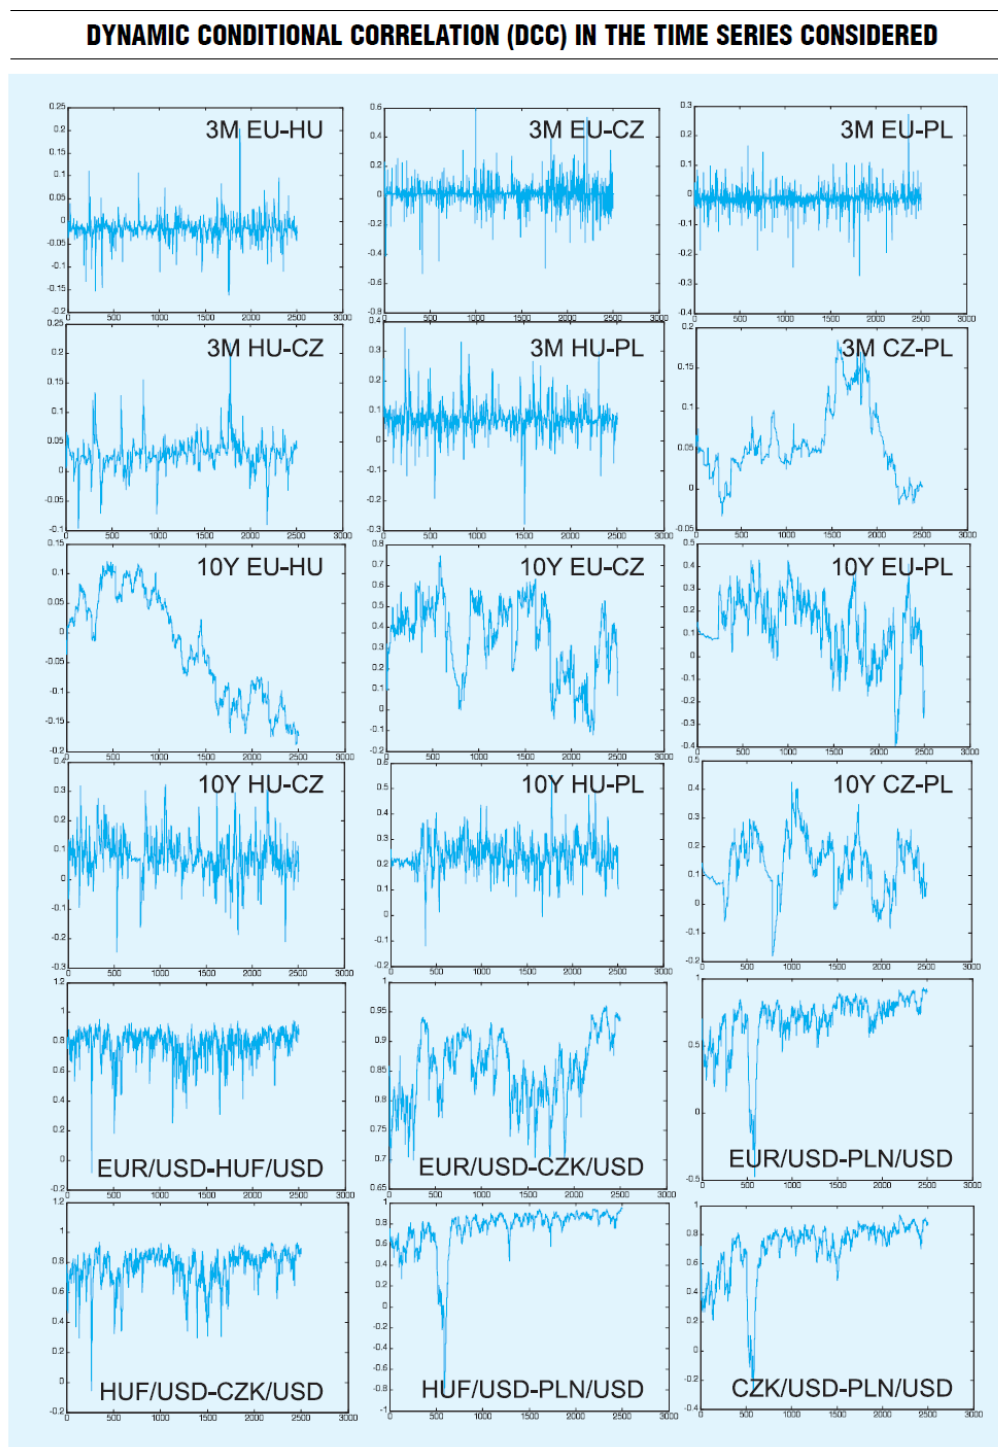


Figura 2.1 Corelațiile condiționale dinamice ale seriilor analizate

Sursa: Gábor Dávid Kiss, Andreász Kosztópulosz , The Impact of the Crisis on the Monetary Autonomy of Central and Eastern European Countries

Ca și concluzie, criza a dus la o segmentare a piețelor de obligațiuni și la o integrare mai puternică a piețelor valutare din zona CEE. Deasemenea comparând întreaga perioadă analizată cu subperioadele (înainte de criză și după criză) s-a ajuns la concluzia că în timp ce nu există diferențe semnificative între comportamentul colectiv observat în perioadele în care BCE a crescut sau a scăzut rata de bază, rezultatele din sub-eșantioane diferă față de cele din eșantionul întreg. Deciziile BCE au influențat doar piața de obligațiuni Cehă. Astfel deciziile luate de către Banca Centrală Europeană pentru a controla criza nu au avut un efect semnificativ asupra țărilor din CEE.

Efectul de contagiune dintre țările BRICS: o aplicare a modelului multivariat GARCH – autor: Lumengo Bonga Bonga (2017)

În lucrarea aceasta se analizează efectul de contagiune dintre Africa de Sud și celelalte țări din BRICS pe perioada 1996-2012. Având în vedere că Africa de Sud este cea mai nouă țară care s-a alăturat în BRICS (2010), se folosește modelul multivariat VAR-DCC-GARCH pentru a vedea corelațiile dintre aceasta și celelalte țări BRICS. Magnitudinea corelațiilor dintre Africa de Sud și celelalte țări BRICS a fost analizat luând în considerare crize globale sau crize specifice țărilor BRICS (criza valutară rusă din 1998, criza valutară din Africa de Sud din 2002, criza braziliană din 2002 și criza asiatică din 1997).

Concluziile lucrării sunt că Brazilia și Africa de Sud sunt egal afectate în timpul crizelor ce apar în interiorul granițelor lor, ceea ce indică faptul că există interdependențe între piețele de capital ale celor două țări. Rezultatele empirice arată deasemenea că Africa de Sud este mai afectată de crizele din China, India, și Rusia decât aceste țări sunt influențate de crizele ce au loc în Africa de Sud. Rezultatele obținute pot fi de folos creării de noi politici economice în cadrul BRICS sau investitorilor sau managerilor de portofolii ce consideră investirea în BRICS.

2.2. Studii în care se previzionează valorile activelor financiare folosind modelul GARCH

Un tutorial GARCH cu R – autori: Marcelo Scherer Perlin, Mauro Mastella, Daniel Francisco Vancin, Henrique Pinto Ramos (2021)

În această lucrare s-a folosit modelul GARCH pentru a previziona cât de mult timp va fi nevoie după ultima criză (2020), pentru ca indexul Ibovespa (indicator al pieței de capital braziliene) să ajungă din nou la maximul său istoric. Datele empirice reprezintă valorile de închidere zilnice ale indexului și acoperă perioada dintre anii 2000 și 2020, inclusiv criza financiară din 2009 și prezentul episod al pandemiei COVID-19. Primul pas a fost calcularea vectorului de rentabilități logaritmice zilnice. Seria cu rentabilități logaritmice este o serie staționară și are mai multe proprietăți favorabile analizei statistice (Quigley and Ramsey, 2008). Următorul pas a fost testarea pentru a vedea dacă există un efect ARCH în date. Pentru acest lucru s-a folosit testul multiplicator Lagrange (Engle, 1982) și s-a observat că există efecte de tip ARCH în seria de date.

Următorul pas a fost estimarea modelului GARCH. În lucrare au fost estimate trei versiuni ale modelului GARCH, fiecare cu o formulă diferită pentru volatilitate, dar cu același număr de lag-uri și aceeași asumție pentru distribuție. S-a constatat că toți coeficienții sunt statistic semnificativi și că valoarea constantei din ecuație este pozitivă ceea ce implică faptul că indexul Ibovespa are mari șanse să aibă un randament pozitiv și în creștere pe termen lung.

Cu ajutorul statisticilor log-likelihood, Akaike information criteria (AIC) și Bayesian information criterion (BIC) s-a căutat modelul GARCH care să potrivească cât mai bine datele din serie. Cu cât AIC și BIC au valori mai mici cu atât modelul este mai potrivit. După ce s-au calculat valorile AIC și BIC pentru mai multe modele GARCH, s-a ajuns la concluzia că modelul $ARMA(0,0)+eGARCH(2,1)$ este cel mai bun model.

În următorul pas se folosește modelul $ARMA(0,0) + eGARCH(2,1)$ pentru a previziona momentul în care indexul va ajunge din nou la valoarea maximă istorică.

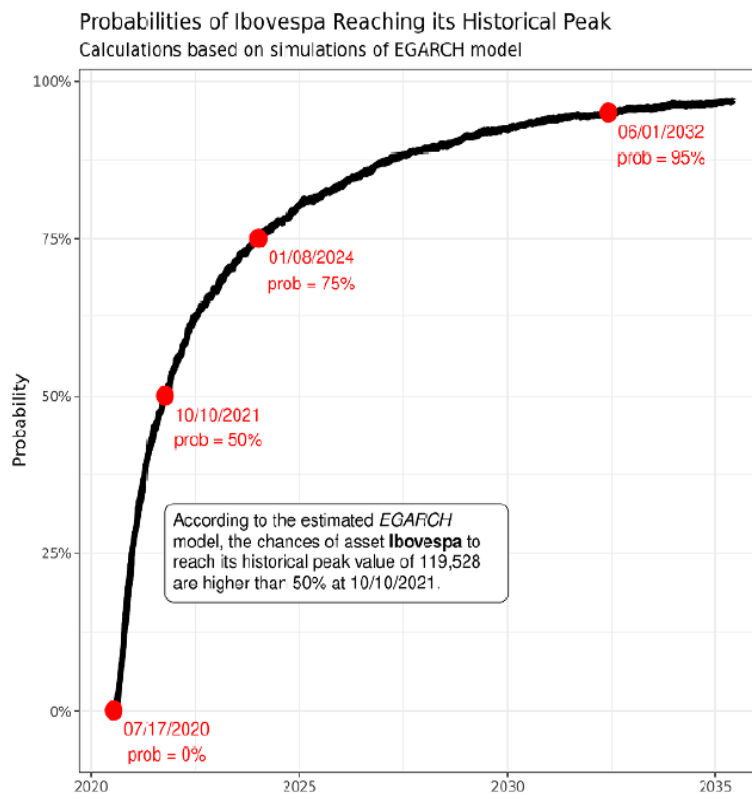


Figura 2.2 Previziunea indicelui Ibovespa

Sursa: Marcelo Scherer Perlin, Mauro Mastella, Daniel Francisco Vancin, Henrique Pinto Ramos (2021), *A GARCH Tutorial with R*

Concluzia la care s-a ajuns în urma analizei a fost că indexul Ibovespa poate ajunge la maximul istoric cu o probabilitate de 50%, în luna octombrie a anului 2021. Cu cât perioada de timp este mai mare cu atât probabilitatea ca maximul istoric să fie atins este mai mare.

Studiu al abilității de prezicere a modelului DCC-GARCH și a aplicațiilor Value-at-risk asupra piețelor de schimb valutare scandinave – autori: Tim Andersson-Säll și Johan S. Lindskog (2019)

Acest studiu are ca obiectiv analizarea și prezicerea valorilor piețelor de schimb valutar scandinave (Norvegia, Suedia și Danemarca) folosind un model DCC-GARCH. Modelul a fost estimat folosind valorile zilnice de deschidere ale piețelor valutare scandinave în perioada 2004-2013, aceste date capturând și informația din timpul crizei financiare din 2008 și a crizei din zona euro de la începutul anului 2010. Prezicerea a fost realizată pentru valorile zilnice din anul 2014. Rezultatele au arătat că modelul DCC-GARCH a prezis cu acuratețe fluctuațiile din corelația condițională, dar a subestimat magnitudinea acestora. Deasemenea, modelul DCC-GARCH prezintă o bună performanță a prezicerii a valorii la risc pentru diferite portofolii ce conțin monede scandinave.

2.3 Studii ce investighează legătura dintre riscul activelor financiare și al diferitelor mărfuri

Analiză volatilității dinamice dintre piața chineză a valorile futures ale combustibililor fosili (SHFE) și indicele bursier al piețelor future (CSI 300) bazată pe modelul DCC-GARCH cu o abordare semi-nonparametrică – autori: Yang Hou, Steven Li, Fenghua Wen (2019)

Această lucrare arată câteva rezultate noi ce țin de influența efectului de volatility spillover dintre valorile futures ale combustibililor fosili și valorile futures ale CSI 300 din China luând ca date prețurile zilnice de la data de 17 mai 2010 până la data de 30 martie 2018.

Efectul de volatility spillover apare atunci când volatilitatea unei piețe este influențată atât de valorile trecute ale sale cât și de volatilitatea unor piețe externe. Pentru a observa volatilitatea în timp se folosește un model DCC-GARCH cu o abordare semi-nonparametrică ce i-a în considerare un exces marginal al boltirii și al asimetriei. În urma analizei s-a constatat că există efect de volatility spillover atât asupra combustibililor fosili cât și asupra indicelui bursier al piețelor future. Un shock informațional ce apare într-una dintre piețe face ca în medie volatilitatea din cealaltă piață să crească. Deasemenea s-a constatat că efectul de volatility spillover al piețelor futures asupra valorilor futures

ale combustibililor fosili este mult mai accentuat decât vice versa. Asta arată faptul că valorile futures ale CSI 300 joacă un rol principal în procesarea informațională. Această lucrare este de folos investitorilor ce investesc în combustibili fosili sau a managerilor de portofolii ce au în vedere piețele futures din China.

Piața financiară și piața alimentelor au devenit mai integrate? – autor Georg V. Lehecka (2014)

Acest articol analizează mișcările comune și integrarea dintre comoditățile agregate de alimente și prețurile acțiunilor în perioada 1990 și 2012. Datele au fost împărțite în sub-eșantioane luând ca și criterii schimbările structurale (2004) și criza financiară din 2008. Pentru a verifica mișcările comune dintre randamentele FAO (Food Price Index) și MSCI (World Stock Market Index) s-au analizat corelările randamentelor, distribuția randamentelor, cointegrarea și testul de cauzalitate Granger (pentru a vedea dacă prețurile unei piețe ajută la prezicerea prețurilor celeilalte piețe).

Rezultatele empirice au arătat că există doar o mică creștere în mișcările comune ale indicilor datorită unor schimbări structurale, ca și schimbarea politicilor agricole sau creșterea cererii datorită dezvoltării țărilor emergente. Totuși creșterea mișcărilor comune devine substanțial mai semnificativă în timpul crizei financiare din 2008.

2.4 Studii ce analizează piața emisiilor de carbon

Modelarea randamentelor prețurilor spot și futures ale carbonului cu ajutorul modelelor GARCH și MRS (Markov Regime Switching) – autori: Alexander C. M. Zeitlberger și Alexander Brauneis (2014)

Această lucrare folosește valorile spot și futures pentru a analiza mișcările randamentelor prețurilor carbonului în Schema Uniunii Europene de comercializare a emisiilor (EU ETS) în perioada 2008-2012.

Înțelegerea proprietăților randamentelor prețurilor carbonului este în special importantă pentru industriile ce trebuie să respecte sistemul pentru tranzacționare a emisiilor sau pentru managerii de risc sau speculatori.

În lucrare se caută crearea unui model care să captureze cât mai bine comportamentul prețurilor carbonului, iar pentru acest lucru s-a folosit o multitudine de modele GARCH și alte modele cum ar fi MRS (Markov Regime Switching) sau modele din familia modelelor ARIMAX. Toate modelele au folosit rentabilitatea logaritmică obținută din seria de timp a prețurilor carbonului.

Pentru început s-a calculat un model univariat pentru a vedea caracteristicile serilor de timp, capturând astfel existența clusterelor de volatilitate sau a efectelor de asimetrie ale volatilității. Pentru început s-a folosit un model ARMA-GARCH pentru a descrie aceste proprietăți, atât pentru randamentele spot cât și pentru cele futures, iar apoi s-au folosit modele GARCH din ce în ce mai complexe și modelul Markov regime switching.

În urma analizei s-a ajuns la concluzia că piața carbonului este similară cu alte piețe financiare care au volatilitate ce variază în timp pronunțată, astfel putând fi analizată prin diferite modele GARCH. S-a constatat că modelele GARCH sunt mai potrivite pentru seria de date decât modelele MRS. Deasemenea randamentele spot și futures sunt cel mai bine modelate când folosim o distribuție normală a erorilor în modele.

Testul de cauzalitate a arătat că valorile futures trecute au impact semnificativ asupra valorilor spot ulterioare. Astfel putem spune că piața futures conduce sau influențează piața spot ceea ce reprezintă o informație valoroasă pentru randamentele pieței spot. Această concluzie este susținută și de faptul că există un volum de tranzacționare mult mai mare pe piața futures decât cel de pe piața spot. Deasemenea este susținută și prin rezultatele testului de cauzalitate Granger, care arată că randamentele futures Granger-cauzează randamentele spot, dar nu și vice versa. Cu ajutorul acestor informații, s-a ajuns la concluzia că modelul ARMAX(1,0,1)-(1,1)-GED este cel mai potrivit pentru modelarea prețurilor spot, iar pentru modelarea prețurilor futures, modelul AGARCH(0,0)-(1,1)-GED este recomandat.

Efectul dinamic de volatility spillover dintre piața Europeană de comercializare a carbonului (EU ETS) și piața energiei fosile – autori: Yue-Jun Zhang și Ya-Fang Sun (2015)

Această lucrare analizează corelațiile într-o manieră dinamică în timp și efectul de volatility spillover (volatilitatea unei piețe afectează o altă piață) dintre prețurile carbonului și cele ale energiei fosile. Pentru această analiză se folosesc modelele DCC-GARCH și BEKK-GARCH, iar datele folosite sunt prețurile futures zilnice ale carbonului și cele trei surse de energie fosile (cărbune, gaze naturale și petrol) pe perioada 2 ianuarie 2008 – 30 septembrie 2014.

Rezultatele indică faptul că există volatility spillover semnificativ de la piața cărbunelui către piața carbonului și de la piața carbonului către piața gazelor naturale, în timp ce nu există nici un efect semnificativ de volatility spillover între piața carbonului și a petrolului. O altă concluzie la care s-a ajuns în urma analizei este că piața carbonului și piețele energiei fosile sunt semnificativ corelate pozitiv în timp, cea mai mare corelație fiind între piața carbonului și piața cărbunelui. Ca și ultimă concluzie s-a constatat că scăderea prețurilor piețelor energiei fosile (cu excepția petrolului unde avem un impact asimetric) poate avea un impact mai puternic asupra volatilității prețului carbonului decât creșterea acestora cu aceeași intensitate. Aceste rezultate pot fi de folos managerilor de portofolii pentru a gestiona riscul portofoliului și pentru industriile ce au emisii de carbon și trebuie să respecte sistemul pentru tranzacționare a emisiilor.

Capitolul 3: Expunerea la riscul global al piețelor de capital din Centrul și Estul Europei

Prin intermediul acestui studiu vom încerca să cuantificăm riscul expunerii la piețele globale al țărilor din CEE. Studiul se va realiza în două părți, iar în prima parte a studiului am împărțit baza de date în trei subperioade: înainte de criza din 2007, în timpul crizei (2007-2009), și după criză (2010-2019), și am analizat în ce măsură rentabilitatea globală influențează rentabilitatea locală. În a doua parte a studiului am măsurat într-o manieră dinamică corelările dintre indicii locali și indicii globali, acest lucru ajutându-ne să observăm cât de tare sunt expuse piețele locale la riscul marilor piețe internaționale.

3.1. Baza de date

Datele au fost preluate de pe platforma Thomson Reuters Eikon și reprezintă indicii țărilor din Europa Centrală și de Est și anume România (BET), Ungaria (BUX), Cehia (PX), Rusia (MOEX), Polonia (WIG) și indicele global MSCI. Indicele MSCI (Morgan Stanley Capital International) este conceput pentru a reprezenta performanțele acțiunilor companiilor mari și mijlocii, pe termen mediu, din 24 de piețe dezvoltate.

Deasemenea pentru a doua parte a lucrării am preluat unii dintre cei mai importanți indici internaționali cum ar fi indicele Germaniei (DAX30), indicele Japoniei (Nikkei225), indicele Marii Britanii (FTSE100), indicele Franței (CAC40) și indicele Statelor Unite ale Americii (S&P500).

Datele preluate sunt prețurile zilnice de închidere (close) ale indicilor pe o perioadă de 16 ani, de la începutul anului 2004 până la sfârșitul anului 2019. Am avut nevoie de aceste date pentru a calcula rentabilitatea logaritmică zilnică a indicilor.

În tabelele de mai jos avem calculate rentabilitățile medii zilnice (\bar{R}_t) și abaterile medii pătrățice ($\bar{\sigma}_t$) pentru fiecare indice în parte. Statisticile descriptive din tabelul 3.1 sunt împărțite pe trei perioade și anume înainte, în timpul și după criză, iar cele din tabelul 3.2 sunt realizate pentru toată perioada analizată 2004-2019. În ultimele două coloane am testat egalitatea dintre varianțe.

Perioade	2004-2007		2007-2009		2010-2019		2004-2007	2007-2009
Indici	\bar{R}_t	$\bar{\sigma}_t$	\bar{R}_t	$\bar{\sigma}_t$	\bar{R}_t	$\bar{\sigma}_t$	F test	F test
							(F crit)	(F crit)
BET	0.001501	0.014991	-0.001396	0.026055	0.0003	0.010897	3.0378	5.7376
							(1.1324)	(1.1147)
BUX	0.000426	0.011946	-0.00134	0.020781	-0.0000002	0.011193	0.3379	3.3901
							(0.8838)	(1.1136)
PX	0.00075	0.009658	-0.002562	0.019654	-0.000205	0.008841	0.2478	4.9717
							(0.8834)	(1.1145)
MOEX	0.001309	0.019377	-0.00126	0.038159	0.000329	0.011982	0.2897	9.4757
							(0.8834)	(1.1136)
WIG	0.000588	0.009477	-0.001636	0.015833	-0.000391	0.008356	0.3602	3.5958
							(0.8834)	(1.1146)
MSCI	0.000467	0.006173	-0.00076	0.017	0.000247	0.00781	0.1287	5.1045
							(0.8839)	(1.1147)
DAX	0.000542	0.008079	-0.000516	0.018716	-0.000116	0.009937	0.1899	3.4553
							(0.8815)	(1.1146)
NIKKEI225	-0.000059	0.008581	-0.000731	0.018213	-0.000081	0.009016	0.2157	4.060
							(0.8818)	(1.1146)
FTSE100	0.000418	0.007679	-0.000398	0.019301	0.000131	0.009303	0.2146	4.2887
							(0.8818)	(1.114)
CAC40	0.000173	0.007147	-0.001226	0.016889	-0.000122	0.00999	0.2761	2.5409
							(0.8818)	(1.1146)
S&P500	0.000347	0.007201	-0.000413	0.020293	0.000278	0.008593	0.1477	5.5953
							(0.8818)	(1.1146)

Tabelul 3.1 Statistici descriptive

După cum se poate vedea în tabelul 3.1, în perioada de dinaintea crizei, rentabilitățile indicilor sunt pozitive (exceptând Nikkei225), ceea ce arată că economia globală urma la vremea respectivă un trend ascendent. Se poate observa deasemenea că cele mai mari rentabilități medii sunt ale indicilor BET și MOEX. Acest lucru se datorează faptului că România și Rusia sunt țări în curs de dezvoltare ce au o creștere economică semnificativă în comparație cu marile puteri globale ca și SUA sau Germania, care au deja o economie dezvoltată. În timpul crizei toți indicii au avut rentabilități negative, ceea ce arată că recesiunea economică a fost resimțită și în majoritatea țărilor din CEE, chiar dacă acestea au un grad de integrare mai mic cu piața globală, decât marile puteri internaționale. După perioada de criză, rentabilitățile medii ale indicilor cresc, dar nu la nivelul de dinaintea crizei, multe dintre acestea rămânând negative.

Se poate observa că în timpul crizei abaterea medie pătratică este semnificativ mai mare decât înainte și după criză în cazul tuturor indicilor. Ce este interesant de observat este faptul că după criză valorile abaterilor sunt mai mici și decât înainte de criză, în cazul indicilor țărilor din CEE, ceea ce înseamnă deasemenea că riscul mediu zilnic este mai mic. Acest lucru poate însemna că economia țărilor a devenit mai stabilă după criză.

În ultimele două coloane ale tabelului 3.1 am testat cu ajutorul testului F, dacă varianțele din subperioadele analizate sunt egale. Varianțele sunt egale dacă valoarea obținută în urma testului F este mai mică decât valoarea critică a lui F. Se poate observa că nu există diferențe semnificative la un prag de risc de 5% atunci când comparăm varianțele de dinaintea de criză și din timpul crizei. Acest lucru se schimbă când comparăm perioada din timpul crizei cu cea de după criză. Varianțele diferă semnificativ la un prag de risc de 5%, valorile lui F fiind mult mai mari decât cele ale lui F critic în toate cazurile.

Perioadă	2004-2019	
Indici	\bar{R}_t	$\bar{\sigma}_t$
BET	0.000361	0.014820
BUX	-0.000078	0.013078
PX	-0.000292	0.011144
MOEX	0.000375	0.019102
WIG	-0.000322	0.009972

MSCI	0.000163	0.009299
DAX	-0.000001	0.011036
NIKKEI225	-0.000165	0.010651
FTSE100	0.000128	0.010893
CAC40	-0.000186	0.010529
S&P500	0.000201	0.010693

Tabelul 3.2 Statistici descriptive pentru întreaga perioadă analizată

În tabelul 3.2 avem rentabilitățile medii zilnice și abaterile medii pătratice calculate pentru întreaga perioadă analizată. Chiar dacă unii indici au rentabilități negative, economia globală per total urmează un trend ascendent. Ne putem da seama de acest lucru prin intermediul indicelui global MSCI care are o rentabilitate pozitivă.

Indicele MSCI are o abatere medie pătratică mai mică decât restul indicilor, deoarece acesta este un portofoliu internațional, ceea ce îl face mai bine diversificat decât restul indicilor.




Figura 3.1 Rentabilitatea logaritmică a indicelui MSCI

În graficul din figura 3.1 putem observa cum a evoluat rentabilitatea logaritmică a indicelui global MSCI și putem vedea că în timpul crizei a avut o variație semnificativă față de restul perioadei analizate.

3.2. Metodologia de studiu

În modelul de piață folosit vom avea randamentul pieței locale explicat de randamentul pieței globale, astfel vom avea o idee despre cât de mult este influențată piața locală de cea globală, deasemenea cât de expusă riscului este piața locală datorită pieței globale.

$$R_{j,t} = \alpha_j + \beta_j R_{M,t} + \varepsilon_{j,t}$$

$R_{j,t}$, rentabilitatea titlului j la momentul t

$R_{M,t}$, rentabilitatea pieței globale la momentul t

$\varepsilon_{j,t}$, rezidurile titlului j la momentul t

Prima parte a ecuației ($\alpha_j + \beta_j R_{M,t}$) reprezintă factorii sistematici care influențează rentabilitatea indicelui, iar a doua parte ($\varepsilon_{j,t}$) reprezintă factorii specifici fiecărui titlu în parte.

Rentabilitatea reprezintă cât de performant a fost un activ/portofoliu/indice într-o anumită perioadă de timp (zilnic, lunar, anual). Presupunând că activul financiar generează fluxuri care sunt reinvestite în timp continuu, voi determina rentabilitatea continuă sau logaritmică după relația:

$$R_t^L = \ln \left(\frac{C_t}{C_{t-1}} \right)$$

R_t^L , rentabilitatea logaritmică la momentul t

C_t , prețul de închidere la momentul t

C_{t-1} , prețul de închidere la momentul t-1

În modelul nostru, care determină cât de mult riscul la care este expusă piața locală este influențat de piața globală, avem ca variabile endogene rentabilitatea fiecărui indice al piețelor țărilor din CEE. Ca și variabilă exogenă avem rentabilitatea indicelui global MSCI.

Modelul a fost realizat pentru fiecare indice local pe 3 perioade de timp distincte și anume: înainte de criza din 2007, în timpul crizei și după criză. Având în vedere că declinul economic din 2007 a început decalat în țările din CEE, perioadele variază de la o țară la alta. Prețul indicilor BET, BUX, PX și WIG a început să scadă la începutul lunii noiembrie. În cazul indicelui MOEX, declinul economic s-a resimțit mai târziu, prețurile începând să scadă semnificativ la începutul anului 2008.

Odată creat modelul, ceea ce ne interesează pe noi cu adevărat este coeficientul beta (β) care ne arată cât de volatilă este piața locală și cu cât se va modifica variabila endogenă la o modificare cu o unitate a variabilei exogene.

Coeficientul beta poate fi estimat prin intermediul următoarei formule:

$$\hat{\beta}_j = \frac{cov(R_j, R_M)}{\sigma^2(R_M)}$$

Deasemenea ne mai interesează și coeficientul de determinație (R^2) care ne arată în ce proporție este influențat randamentul local de cel global sau cu alte cuvinte, influența pieței globale asupra pieței locale. Deasemenea coeficientul de determinație este o măsură inversă a informativității prețurilor. Informativitatea prețurilor este reprezentată de factorii specifici din modelul de piață. Prin urmare, putem spune că, cu cât R^2 este mai aproape de 1, cu atât informativitatea prețurilor este mai mică (factorii specifici sunt mai puțin semnificativi) sau cu cât R^2 este mai aproape de 0, cu atât informativitatea prețurilor este mai mare.

Formula coeficientului de determinație este următoarea:

$$R^2 = \frac{\beta_j^2 \sigma^2(R_M)}{\sigma^2(R_j)}$$

Pentru a doua parte a lucrării am folosit un model multivariat DCC (Dynamic Conditional Correlation) GARCH (1,1) care măsoară riscul într-o manieră dinamică în timp folosind două sau mai multe serii de timp. Volatilitățile financiare tind să evolueze împreună în timp (Orskaug, 2009), așa că folosim modelul pentru a vedea cum arată această evoluție. Folosirea unui astfel de model multivariat ar trebui să ducă la modele empirice mai relevante decât folosind modele univariate separat.

Am utilizat modelul DCC GARCH pe software-ul statistic R, făcând de data aceasta perechi între indicii locali și indicii internaționali (DAX30, Nikkei225, FTSE100, CAC40, S&P500). În acest tip de model pentru a estima valoarea indicelui de la momentul t vom lua în considerare valoarea indicelui la momentul $t-1$, volatilitatea de la momentul $t-1$ și eroarea (inovația) de la momentul t .

$$\sigma_{\varepsilon_t}^2 = h_t = a_0 + a_1 \varepsilon_{t-1}^2 + a_2 h_{t-1}$$

h_t , varianța condițională de la momentul t

ε_{t-1}^2 , eroarea (inovația) de la momentul $t-1$

h_{t-1} , varianța condițională de la momentul $t-1$

3.3. Rezultate empirice

Pentru început am calculat randamentul zilnic al fiecărui indice, inclusiv indicele MSCI și DAX și am introdus datele în aplicația EViews pentru a crea ecuația modelului de piață. Am creat câte o ecuație pentru fiecare indice local și indicele MSCI pentru a vedea influența pieței globale asupra piețelor locale. De asemenea am creat câte o ecuație pentru fiecare indice local și indicele DAX pentru a vedea efectul piețelor europene asupra piețelor locale din CEE, obținând următoarele rezultate:

Indice	2004-2007			2007-2010			2010-2019		
	α	β	R^2	α	β	R^2	α	β	R^2
	(t-stat)	(t-stat)		(t-stat)	(t-stat)		(t-stat)	(t-stat)	
BET	0.001369*** (2.832504)	0.259847*** (3.363071)	0.010659	-0.000781 (-0.812234)	0.801222*** (14.2005)	0.272758	0.000192 (0.95268)	0.516424*** (20.10129)	0.138269
BUX	0.000238 (0.630263)	0.413105*** (6.793483)	0.044742	-0.000860 (-1.050246)	0.497456*** (10.42122)	0.166928	-0.000178 (-0.874537)	0.608290*** (23.43534)	0.180737
PX	0.000508* (1.731580)	0.527344*** (11.20648)	0.114237	-0.001934* (-2.748253)	0.636670*** (15.40909)	0.303736	-0.000356** (-2.341740)	0.569018*** (29.41933)	0.255958
MOEX	0.000776 (1.362670)	1.187662*** (13.34181)	0.152326	-0.000387 (-0.279147)	1.286219*** (16.36472)	0.351148	0.000135 (0.647234)	0.767243*** (28.89139)	0.250235
WIG	0.000400 (1.369678)	0.442303*** (9.353706)	0.082100	-0.001286** (-2.095443)	0.395817*** (11.10831)	0.184220	-0.000519*** (-3.467046)	0.473592*** (24.84026)	0.197509

(indice local; MSCI)

Tabelul 3.3 Ecuatiile volatilităților dintre indicii analizați și indicele MSCI

*** -semnificativ la un prag de risc de 1%

** -semnificativ la un prag de risc de 5%

* -semnificativ la un prag de risc de 10%

Din datele de tabelul 3.3 putem observa că valorile coeficientului beta sunt semnificative la un prag de risc de 1%. Atât coeficientul beta cât și coeficientul de determinație cresc în timpul crizei, iar după criză scad înapoi, dar nu atât de mult încât să ajungă la nivelul de dinainte de criză. Acest lucru se întâmplă în cazul tuturor indicilor din tabelul 3.3. Cu alte cuvinte în timpul crizei volatilitatea indicilor crește foarte mult și deasemenea influența pieței globale crește din ce în ce mai tare. După perioada de criză, chiar dacă cei doi coeficienți scad, piața locală pare mai integrată cu piața globală decât înainte de criză. Concluzionăm acest lucru, deoarece coeficienții de determinație de după criză au valori mai mari decât înaintea crizei, ceea ce poate însemna că indicii locali sunt mai dependenți de indicele global MSCI (Jiang, 2017).

Luând ca exemplu indicele BET, în perioada de dinainte de criză (5 ianuarie 2004 – 31 octombrie 2007) se poate observa că beta (β) avea o valoare de 0.259847 ceea ce înseamnă că la fiecare modificare cu o unitate a indicelui pieței globale, indicele BET se modifică în medie cu aproximativ

0.25 unități. Acest beta arată deasemenea că indicele BET avea o volatilitate scăzută. Coeficientul de determinație în cazul indicelui BET în valoare de aproximativ 1.06%, era mic în comparație cu ceilalți indici analizați. Coeficientul de determinație arată că indicele MSCI avea o influență foarte mică asupra indicelui BET înainte de criză. În timpul crizei (1 noiembrie 2007 – 31 decembrie 2009) indicele BET a devenit mai volatil ($\beta = 0.80122$), dar nu a depășit volatilitatea indicelui MSCI. Coeficientul de determinație arată că aproximativ 27.27% din variația randamentului indicelui BET este influențată de variația randamentului indicelui MSCI. O creștere foarte semnificativă față de perioada de dinainte de criză. Acest lucru s-a întâmplat atât de abrupt deoarece integrarea globală devine din ce în ce mai pronunțată în România, unul din argumente fiind aderarea României la Uniunea Europeană din 2007, chiar înaintea perioadei de criză. Una din consecințele integrării țărilor europene este libera circulație a forței de muncă în interiorul UE (Guild, 2017). În România, migrația forței de muncă este foarte accentuată, țara suferind o pierdere de aproximativ 17% din populație, cei mai mulți fiind localizați în alte țări UE (Pirvu, Badarcea, Manta, & Florea, 2018). După perioada de criză (1 ianuarie 2010 – 31 decembrie 2019) cei trei coeficienți scad odată cu revenirea stabilității economice, însă nu scad până la nivelul precedent crizei.

Indice	2004-2007			2007-2010			2010-2019		
	α (t-stat)	β (t-stat)	R^2	α (t-stat)	β (t-stat)	R^2	α (t-stat)	β (t-stat)	R^2
BET	0.001620*** (3.451441)	0.101426* (1.753917)	0.002178	-0.001236 (-1.191282)	0.585145*** (10.20221)	0.162573	0.000312 (1.467392)	0.234039*** (10.93743)	0.045597
BUX	0.000206 (0.555588)	0.436865*** (9.524346)	0.085383	-0.000943 (-1.237627)	0.613752*** (14.65343)	0.285832	0.000021 (0.104722)	0.464571*** (22.55046)	0.170109
PX	0.000498* (1.700765)	0.423736*** (11.68933)	0.123462	-0.002198*** (-3.044131)	0.582740*** (14.10676)	0.267930	-0.000184 (-1.164805)	0.404046*** (25.41388)	0.205119
MOEX	0.000807 (1.357917)	0.782554*** (10.69159)	0.104500	-0.000717 (-0.482985)	1.090244*** (13.84818)	0.283141	0.000364 (1.625935)	0.486437*** (21.61659)	0.160162
WIG	0.000396 (1.365338)	0.372118*** (10.31830)	0.098433	-0.001416** (-2.513659)	0.490862*** (15.75535)	0.313653	-0.000366** (-2.559481)	0.438145*** (30.40909)	0.270510

(indice local; DAX) Tabelul 3.4 Ecuatiile volatilităților dintre indicii analizați și indicele DAX

*** -semnificativ la un prag de risc de 1%

** -semnificativ la un prag de risc de 5%

* -semnificativ la un prag de risc de 10%

În cazul perechilor cu indicele DAX se poate observa aceleași trenduri în evoluția coeficientului beta și a coeficientului de determinație. Avem creștere în valorile coeficienților în timpul crizei și scădere după criză, dar nu la nivelul de dinaintea declinul economic.

Luând ca exemplu din nou indicele BET vedem că beta a crescut în timpul crizei la 0.585145, ceea ce înseamnă că la fiecare modificare a rentabilității indicelui DAX cu o unitate, rentabilitatea indicelui BET se va modifica cu 0.58 unități. Coeficientul de determinație al indicelui BET a crescut în timpul crizei de aproximativ 80 de ori, de la 0.2% la 16.25%, aceasta fiind cea mai mare creștere dintre indicii de mai sus. Altfel spus, 16% din variația indicelui BET este cauzată de variația indicelui DAX. Acest lucru arătând că economia României a devenit, în timpul crizei, mult mai dependentă față de economia Uniunii Europene.

În a doua parte a lucrării am folosit modelul heteroscedastic DCC GARCH și am analizat corelările zilnice dintre indicii locali și indicii internaționali obținând următoarele rezultate:

Indici	DAX30			Nikkei225			FTSE100		
	DCC α (t-stat)	DCC β (t-stat)	LL LL	DCC α (t-stat)	DCC β (t-stat)	LL LL	DCC α (t-stat)	DCC β (t-stat)	LL LL
BET	0.006383* (1.83106)	0.987181*** (118.18608)	25122.62 (6.33)	0.012349* (1.67733)	0.958143*** (28.35314)	24313.6 (6.41)	0.025796*** (3.82180)	0.956421*** (73.08269)	25266.8 (6.42)
BUX	0.012479** (1.9667)	0.980314*** (84.8419)	25235.96 (6.35)	0.004061*** (2.7954)	0.993961*** (483.7155)	23919.65 (6.35)	0.019429*** (2.6574)	0.935274*** (35.3210)	25109.6 (6.4)
PX	0.008794** (2.42028)	0.985861*** (142.23823)	26382.61 (6.61)	0.004658 (1.47874)	0.988275*** (99.40764)	25023.62 (6.61)	0.030983*** (4.2349)	0.941843*** (54.7697)	26343.54 (6.68)
MOEX	0.013871** (2.1374)	0.977865*** (81.0603)	24094.31 6.17	0.006788 (1.06520)	0.963991*** (30.56687)	23429.12 (6.19)	0.021722*** (3.2057)	0.970087*** (90.3744)	24423.97 (6.3)
WIG	0.009428*** (3.10751)	0.987283*** (221.13674)	26600.03 (6.67)	0.000000 (0.000122)	0.907334*** (13.076727)	25061.97 (6.62)	0.010570*** (2.65845)	0.982424*** (124.08391)	26361.76 (6.68)

Indici	CAC40			S&P500		
	DCC α (t-stat)	DCC β (t-stat)	LL \overline{LL}	DCC α (t-stat)	DCC β (t-stat)	LL \overline{LL}
BET	0.006341* (1.91199)	0.988892*** (146.26596)	25373.73 (6.37)	0.003724** (2.43437)	0.992306*** (334.12046)	25283.78 (6.49)
BUX	0.015118** (1.95225)	0.977462*** (71.79145)	25503.07 (6.4)	0.010201 (0.99009)	0.981189*** (40.51661)	25126.8 (6.47)
PX	0.013152** (2.02877)	0.976777*** (67.19346)	26628.36 (6.65)	0.006071*** (3.1903)	0.990594*** (333.3178)	26224.68 (6.72)
MOEX	0.013512*** (2.99614)	0.977202*** (116.83472)	24378.3 (6.21)	0.007347*** (3.0300)	0.989073*** (260.9813)	24266.33 (6.3)
WIG	0.014553** (2.424242)	0.980122*** (105.769385)	26881.39 (6.71)	0.009785** (2.5294)	0.985181*** (149.5356)	26350.26 (6.76)

*** -semnificativ la un prag de risc de 1%

** -semnificativ la un prag de risc de 5%




* -semnificativ la un prag de risc de 10%

LL- log-likelihood

Tabelul 3.5 Corelările dintre indicii locali și indicii globali

Datorită faptului că alfa și beta din tabelul 3.5 sunt semnificativi, tipul de model DCC GARCH este unul potrivit pentru această bază de date. Log-likelihood (goodness of fit) ne arată cât de bine se potrivește modelul bazei de date. După cum se poate vedea în tabel, valorile log-likelihood sunt mari comparativ cu media acestora, ceea ce înseamnă că modelul este unul potrivit.

În figurile de mai jos avem evoluția corelărilor dintre indicii locali și cei internaționali, obținute prin intermediul modelul DCC GARCH:









Figura 3.2 Corelările dintre indicele BET și indicii globali

În cazul indicelui BET se poate observa că există o creștere în intensitatea corelării în jurul anilor 2007-2009. Cele mai mari corelări apar între indicele BET(România) și indicele FTSE100 (Marea Britanie), în unele momente ajungându-se la corelări de peste 50%, acestea rămânând semnificative și după perioada de criză.










Figura 3.3 Corelările dintre indicele BUX și indicii globali

La indicele BUX se poate observa că există o creștere în intensitatea corelării în jurul anilor 2007-2009 cu majoritatea indicilor. Corelările cu indicele FTSE100 au rămas asemănătoare pe toată perioada analizată. În cazul indicelui Nikei225 corelările au scăzut ușor față de perioada de dinainte de criză, dar per total corelările cu piața japoneză se mențin la niveluri mici pe toată perioada analizată.








Figura 3.4 Corelările dintre indicele PX și indicii globali

În cazul indicelui PX corelările sunt puternice mai ales cu piața germană, engleză și franceză, atingând valori de peste 50% în perioada de criză.



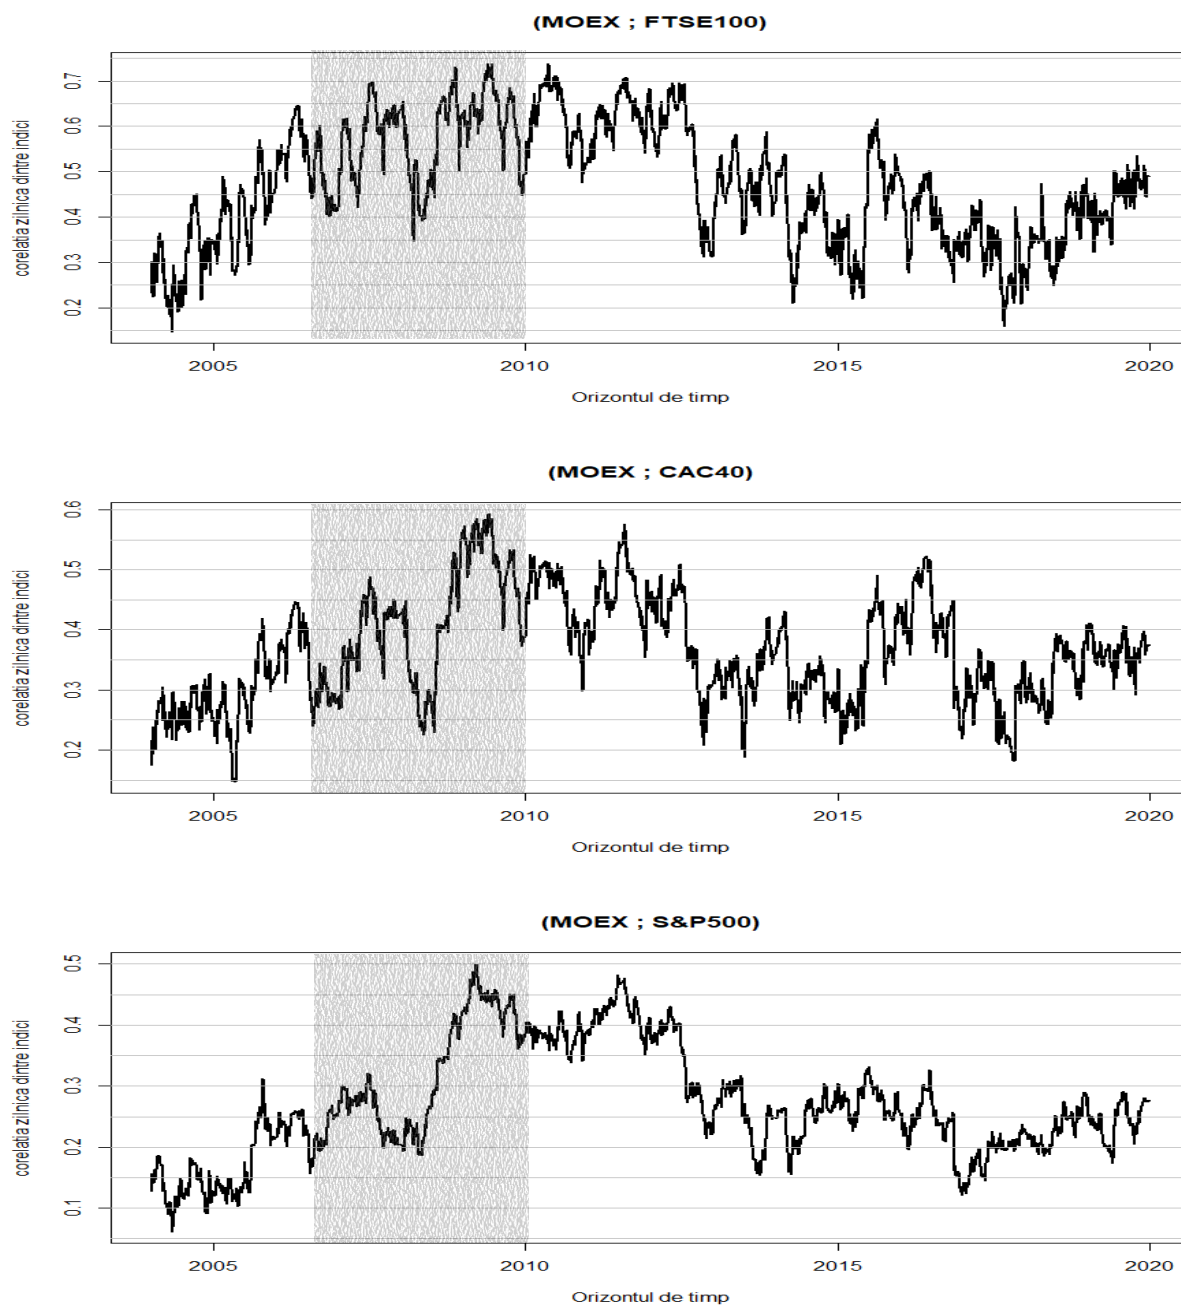





Figura 3.5 Corelările dintre indicele MOEX și indicii globali

Indicele pieței rusești prezintă corelări foarte semnificative cu marii indici europeni, mai ales cu indicele FTSE100 unde corelările trec de pragul de 70% în perioada de criză și chiar și după aceasta.






Figura 3.6 Corelările dintre indicele WIG și indicii globali

Este interesant de observat faptul că indicele Poloniei ajunge la corelările cele mai puternice de 60-70% după perioada de criză, în jurul anilor 2011-2012.

În toate cazurile de mai sus piețele din CEE au corelări extrem de mici cu piața japoneză pe toată perioada analizată. Se poate concluziona că în majoritatea cazurilor de mai sus corelările au crescut semnificativ înainte de criză, iar după criză, trendul corelărilor devine unul descendent. Putem spune deasemenea că deși corelările au început să scadă după criză, acestea nu au ajuns la nivelurile de dinaintea crizei financiare.

Concluzii

Ca și concluzii, putem spune că piețele locale sunt expuse la riscul piețelor globale într-o măsură destul de semnificativă, mai ales în perioada unei crize economice. Chiar dacă economia și-a revenit, piețele locale au rămas semnificativ influențate de către piața globală, făcând comparație cu perioada de dinainte de criză. Deasemenea din a doua parte a lucrării am putut constata că piețele locale devin semnificativ mai corelate cu piețele internaționale în timpul unei perioade de criză. Unul dintre motivele datorită cărora acest lucru s-a întâmplat ar putea fi globalizarea care devine din ce în ce mai accentuată. Globalizarea are avantaje și dezavantaje, unul dintre avantaje ar fi eliminarea taxelor vamale și libera circulație a bunurilor și serviciilor, acest lucru stimulând economia. Pe de altă parte, o prea mare integrare și interdependență economică ar putea duce la o criză de proporții mult mai mari decât cea din 2007 în cazul apariției unor evenimente neprevăzute.

Această lucrare a ajutat la o mai bună înțelegere a dinamicii activelor financiare într-o perioadă de criză resimțită la nivel global. Înțelegerea efectelor crizei financiare este extrem de importantă, deoarece ne dă posibilitatea să răspundem mai repede, bine și eficient atunci când evenimente asemănătoare apar în viitor.

Bibliografie

Andersson-Säll, T., & Lindskog, J. S. (n.d.). *A STUDY ON THE DCC-GARCH MODEL'S FORECASTING ABILITY WITH VALUE-AT-RISK APPLICATIONS ON THE SCANDINAVIAN FOREIGN EXCHANGE MARKET*. 57.

Bodie, Z., Kane, A., & Marcus, A. J. (2013). *Essentials of investments (9th ed)*. McGraw-Hill/Irwin.

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307-327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307-327. doi:10.1016/0304-4076(86)90063-1

Bonga-Bonga, L. (2018). Uncovering equity market contagion among BRICS countries: An application of the multivariate GARCH model. *The Quarterly Review of Economics and Finance*, 67, 36-44. <https://doi.org/10.1016/j.qref.2017.04.009>

Bordo, M. D., & Haubrich, J. G. (2017). DEEP RECESSIONS, FAST RECOVERIES, AND FINANCIAL CRISES: EVIDENCE FROM THE AMERICAN RECORD: DEEP RECESSIONS, FAST RECOVERIES. *Economic Inquiry*, 55(1), 527-541. <https://doi.org/10.1111/ecin.12374>

Bouchaud, J., Potters, M. (1999). *Theory of financial risk: from data analysis to risk management*

Celik, S. (2012). The more contagion effect on emerging markets: The evidence of DCC-GARCH model. *Economic Modelling*, 29(5), 1946-1959. <https://doi.org/10.1016/j.econmod.2012.06.011>

Click, R. W., & Plummer, M. G. (2005). Stock market integration in ASEAN after the Asian financial crisis. *Journal of Asian Economics*, 16(1), 5-28. <https://doi.org/10.1016/j.asieco.2004.11.018>

Danielsson, J.(2011). *Financial risk forecasting*

Engle, R. (2001). GARCH 101: The use of ARCH/GARCH models in applied econometrics. *Journal of Economic Perspectives*, 15(4), 157-168. <https://doi.org/10.1257/jep.15.4.157>

Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987-1007. <https://doi.org/10.2307/1912773>

Guild, E. (2017). *Controlling frontiers: Free movement into and within Europe*. London: Routledge.

Hou, Y., Li, S., & Wen, F. (2019). Time-varying volatility spillover between Chinese fuel oil and stock index futures markets based on a DCC-GARCH model with a semi-nonparametric approach. *Energy Economics*, 83, 119–143. <https://doi.org/10.1016/j.eneco.2019.06.020>

Jiang, Y., Yu, M., & Hashmi, S. (2017). The Financial Crisis and Co-Movement of Global Stock Markets—A Case of Six Major Economies. *Sustainability*, 9(2), 260. <https://doi.org/10.3390/su9020260>

Kiss, G. D., & Kosztópulosz, A. (2012). The impact of the crisis on the monetary autonomy of Central and Eastern European countries. 26.

Lazar, D., Denuit, M. (2009). A multivariate time series approach to projected life tables. *Applied Stochastic Models in Business and Industry* 25(6): 806 – 823. <http://onlinelibrary.wiley.com/doi/10.1002/asmb.781/abstract>

Lehecka, G. V. (2014). Have food and financial markets integrated? *Applied Economics*, 46(18), 2087–2095. <https://doi.org/10.1080/00036846.2014.894634>

Orskaug, E. (2009). *Multivariate DCC-GARCH Model*. 88.

Perlin, M. S., Mastella, M., Vancin, D. F., & Ramos, H. P. (2021). A GARCH Tutorial with R. *Revista de Administração Contemporânea*, 25(1), e200088. <https://doi.org/10.1590/1982-7849rac2021200088>

Pirvu, R., Badarcea, R., Manta, A., & Florea, N. (2018). The link between migration, remittances and economic growth: Empirical evidence from Romania. *Theoretical and Practical Research in the Economic Fields*

Quigley, L., & Ramsey, D. (2008). *Statistical analysis of the log returns of financial assets (Bachelor dissertation)*. University of Limerick, Ireland. Retrieved from <https://www.uni-muenster.de/Stochastik/paulsen/Abschlussarbeiten/Diplomarbeiten/Quigley.pdf>

Reilly, F., Brown, K. (1979). *Investment Analysis and Portofolio Management*

Shaw, H. (1999). *The Diaoyutai/Senkaku Islands dispute: Its history and an analysis of the ownership claims of the P.R.C., R.O.C., and Japan*. University of Maryland School of Law.

Steven P. Peterson (2012). Investment Theory and Risk Management

Tsay, R. S. (2005). Analysis of financial time series (3rd ed.). Hoboken, NJ: John Wiley & Sons.

Zeitlberger, A. C. M., & Brauneis, A. (2016). Modeling carbon spot and futures price returns with GARCH and Markov switching GARCH models: Evidence from the first commitment period (2008–2012). Central European Journal of Operations Research, 24(1), 149–176.
<https://doi.org/10.1007/s10100-014-0340-0>

Zhang, Y.-J., & Sun, Y.-F. (2016). The dynamic volatility spillover between European carbon trading market and fossil energy market. Journal of Cleaner Production, 112, 2654–2663.
<https://doi.org/10.1016/j.jclepro.2015.09.118>

<https://www.investopedia.com/articles/basics/11/biggest-risks-international-investing.asp>

<https://www.investopedia.com/terms/g/generalizedautogressiveconditionalheteroskedasticity.asp>